

WSI Ćwiczenie 2

Algorytm genetyczny

Autor:

Jakub Kowieski

Przedmiot:

WSI, semestr: 21Z

Numer Albumu:

310765

Celem ćwiczenia była implementacja algorytmu genetycznego Hollanda oraz zastosowanie go do znalezienia minimum funkcji f dla wektora czterech liczb całkowitych z zakresu $[-16, 16]$.

Stałe:

RANGE = 10000 - liczba ewolucji (iteracji) algorytmu genetycznego

params - lista parametrów zdefiniowanych (znajduję się w `./utils/params.py`):
(populacja, prawdopodobieństwo krzyżowania, prawdopodobieństwo mutacji)

Założenia:

[1, 0, 1, 0, 0, 1, ...] - populacja zdefiniowana jako lista 20 bitów, gdzie każde kolejne 5 bitów tworzy **individual** (osobnik) - liczbę z przedziału $[-16, 16]$ zakodowaną za pomocą kodu graya

fitting_function - oblicza ocenę (rating) najpierw obliczając wartość funkcji $f(x)$, po czym robimy funkcję przeciwną $g(x) = -f(x)$, by zmienić problem na maksymalizację funkcji **$g(x)$** , i na koniec odejmujemy od wszystkich wartości funkcji $g(x)$ najmniejszą występującą wartość - 1 (dodatkowe -1 jest by nie miał on zerowego prawdopodobieństwa i nie wystąpił wyjątek, gdy wszystkie osobniki w populacji są takie same)

Gdy występuje nieparzysta ilość osobników przy operacji krzyżowania, wtedy jeden z osobników po prostu w niej nie uczestniczy.

Posiadanie modułów:

- numpy
- Matplotlib
- pytest-3

Testowanie i symulacje:

[pytest-3 tests](#) - bardzo proste testy czy algorytm działa poprawnie

[python3 table.py](#) - tworzy plik csv w folderze ./csv z wynikami eksperymentów dla parametrów

[python3 simulation.py](#) - służy do generowania populacji, znajdowania parametrów dla eksperymentów oraz wyświetlania wykresu średniej wartości funkcji $g(x)$.

Legenda:


(Population Size, Crossing Prob, Mutation Prob) - taki zapis to odwołanie się do eksperymentu dla zadanych parametrów

Eksperymenty:


Population Size	Crossing Prob	Mutation Prob	Arithmetic Average	Standard deviation
13	1	0.01	-1.55	0.85
8	0.4	0.2	-1.31	0.53
22	0.8	0.05	-0.99	0.0
15	0.3	0.1	-0.99	0.0
10	0.5	0.15	-0.99	0.0
6	0.6	0.4	-1.67	0.53
19	0.4	0.15	-1.07	0.27
17	0.9	0.08	-0.99	0.0
25	0.5	0.01	-0.99	0.0
8	0.5	0.5	-2.2	0.84

Wnioski:

Algorytm genetyczny Hollanda działa dobrze dla małych wartości prawdopodobieństwa mutacji, a szczególnie dla dużych populacji. Dla mniejszych ma także duże znaczenie, tylko większe wartości mutacji prawdopodobieństwa mogą pomóc z szukaniem rozwiązań dla bardziej oddalonych niż dosyć mała populacja. Dla (8, 0.4, 0.2) i (8, 0.5, 0.5) widzimy że zwiększenie wartości aż o 0.3 pogarsza nam wyniki. Jest to spowodowane zbyt szerokim szukaniem najlepszego osobnika:




(8, 0.4, 0.2)



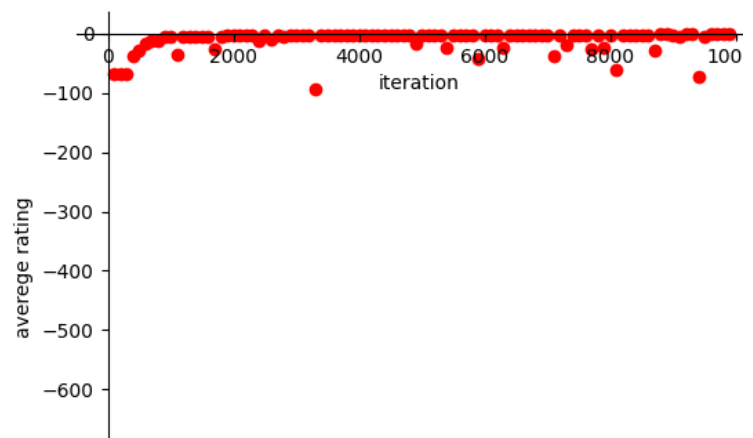
(8, 0.5, 0.5)

Prawdopodobieństwo krzyżowania ma o wiele mniejszy wpływ niż mutacji jeśli chodzi o zauważalną różnicę, ale nadal ważne jest by móc zmienić populację względem samej siebie. Przy większych wartościach (13, 1, 0.01) populacja zmienia się gwałtowniej, a dla (25, 0.5, 0.01) wartości 2 razy mniejszej łagodniej, ale płynniej.



(13, 1, 0.01)



(25, 0.5, 0.01)



Rozmiar populacji nie zmienia charakterystyki średniej wartości funkcji $g(x)$, ale im większa tym możliwa szybsze znalezienie najlepszego osobnika.



Wnioski:

Algorytm Hollanda działa bardzo dobrze dla odpowiednich parametrów, im większa populacja tym lepiej (oczywiście im większa tym czas wykonywania się algorytmu jest większy), wartość prawdopodobieństwo krzyżowania zależy od przypadku i jak chcemy by się zmieniała populacja, a prawdopodobieństwo mutacji powinno być małe aby algorytm mógł nadążać z segregacją lepszych osobników od gorszych, ale nie ma że im mniejsza tym lepsza (np. Dla (13, 1, 0.01) algorytm wcale nie zachowuje się najlepiej).